Co decyduje o sukcesie gry na Steamie? – projekt UM, etap 1

Etap 1 projektu z uczenia maszynowego: dwa publiczne zbiory danych o grach na Steamie, analiza eksploracyjna i pytania badawcze. Kod, dane i raporty: github.com/ProstoKery/steam-ml-project.

1. Informacje o zespole

Nazwisko i imię	ID	GitHub	Zakres pracy
Serhiienko Kyrylo	71897	ProstoKery	zbiór 1 (recenzje, dane tekstowe): pobranie, czyszczenie i analiza eksploracyjna; repozytorium GitHub i README; redakcja raportu
Zavoritnii Roman	72086	yourromanbm-dot	zbiór 2 (gry, dane liczbowe): analiza eksploracyjna i testy statystyczne; połączenie obu zbiorów
razem	–	–	wybór tematu i zbiorów danych, pytania badawcze

2. Temat i dane w skrócie

Steam to największy sklep z grami na komputery: w naszym zbiorze jest ponad 124 tys. gier, a tylko w 2025 roku wydano ich prawie 25 tys. Gracze oceniają gry, pisząc recenzję i zaznaczając, czy polecają grę. Chcemy sprawdzić, co decyduje o dobrej ocenie gry i czy da się ją przewidzieć: z tekstu recenzji (zbiór 1) oraz z cech samej gry (zbiór 2). Oba zbiory łączy identyfikator gry w sklepie Steam (`item_id` = `appid`), dzięki czemu możemy porównać to, co gracze piszą, z liczbami opisującymi grę.

	Zbiór 1: recenzje (język naturalny)	Zbiór 2: gry (dane liczbowe)
Zawartość	tekst recenzji + czy gracz poleca grę	cena, oceny, liczba graczy, gatunki, platformy itd.
Rozmiar	59 305 recenzji, 25 458 użytkowników, 3 682 gry	124 146 gier, 41 kolumn w pliku źródłowym
Okres	recenzje z lat 2010–2016	gry wydane 1997–2026, oceny według stanu z daty zebrania danych (2026)
Źródło	UCSD, zespół J. McAuleya; kopia na Hugging Face	FronkonGames (Steam API + SteamSpy); Hugging Face
Licencja	repozytorium nie podaje licencji; autorzy proszą o cytowanie publikacji (pkt 3.1)	CC BY 4.0 według karty zbioru (metadane repozytorium podają MIT)

3. Informacje o danych

3.1 Zbiór 1: recenzje graczy Steam

- **Pochodzenie:** zbiór recenzji i pakietów gier Steam zebrany przez zespół prof. Juliana McAuleya (University of California San Diego) z publicznych profili społeczności Steam. Używamy części „australian user reviews": recenzje użytkowników z Australii, każda z tekstem i informacją, czy autor poleca grę.
- **Publikacje do cytowania** (wymagane przez autorów zbioru): W.-C. Kang, J. McAuley, *Self-attentive sequential recommendation*, ICDM 2018; M. Wan, J. McAuley, *Item recommendation on monotonic behavior chains*, RecSys 2018; A. Pathak, K. Gupta, J. McAuley, *Generating and personalizing bundle recommendations on Steam*, SIGIR 2017.
- **Skąd pobieramy:** kopia zbioru na Hugging Face recommender-system/steam-review-and-bundle-dataset, plik `australian_user_reviews.json.gz` (6.94 MB), commit `8e9c6b569122fb20668f5da3b0f3970a853fc5d8`, SHA-256 pliku `5b2add00…bf6dfc` (pełna wartość w `data/processed/sources.json`).
- **Podzbiór:** z pięciu plików repozytorium używamy tylko `australian_user_reviews.json.gz`. Pozostałe (biblioteki gier użytkowników, pakiety, recenzje w wersji 2 bez oznaczenia „polecam") nie są potrzebne.
- **Przygotowanie** (`src/01_download_data.py`): każda linia pliku to słownik w składni Pythona, a nie czysty JSON, więc czytamy ją funkcją `ast.literal_eval`. Rozwijamy listę recenzji każdego użytkownika (jedna recenzja = jeden wiersz). Nazwy kont Steam zastępujemy kolejnymi numerami (anonimizacja). Z tekstów „Posted November 5, 2011." i „2 of 3 people (67%) found this review helpful" wyciągamy datę i liczby głosów. Wynik: `data/processed/reviews.csv.gz`, 59 305 wierszy, 14 kolumn.

3.2 Zbiór 2: metadane gier Steam

- **Pochodzenie:** „Steam Games Dataset" (FronkonGames), dane ze sklepu Steam (Steam API) uzupełnione danymi SteamSpy, zebrane otwartym narzędziem FronkonGames/Steam-Games-Scraper. Zbiór obejmuje gry wydane na Steamie (bez DLC, filmów i ścieżek dźwiękowych). DOI: 10.57967/hf/0511.
- **Skąd pobieramy:** FronkonGames/steam-games-dataset, plik `data/train-00000-of-00001.parquet` (192 MB, 124 146 wierszy, 41 kolumn), commit `6a31fcb42082345acc817e176b28849b7c05f248`, SHA-256 `775b17f2…388c5a77`.
- **Podzbiór:** zostawiamy wszystkie gry i 28 z 41 kolumn. Pomijamy 13 kolumn z długimi opisami, adresami URL i multimediami (`detailed_description`, `short_description`, `reviews`, `header_image`, `website`, `support_url`, `support_email`, `metacritic_url`, `score_rank`, `notes`, `screenshots`, `movies`, `packages`). Dodajemy 10 kolumn pochodnych: rok wydania, dolną i górną granicę przedziału liczby właścicieli oraz liczby elementów list (języki, twórcy, wydawcy, kategorie, gatunki, tagi). Wynik: `data/processed/games.csv.gz`, 124 146 wierszy, 38 kolumn.

3.3 Jak odtworzyć dane

1. `python -m pip install -r requirements.txt`
2. `python src/01_download_data.py` – pobiera oba pliki z Hugging Face (w podanych wyżej commitach), przygotowuje podzbiory i zapisuje je w `data/processed/` razem z plikiem

`sources.json` (repozytorium, plik, commit, SHA-256, data pobrania). Nasze dane pobraliśmy 28.10.2026.

3. Analizy: `python src/02_eda_reviews.py`, `src/03_eda_games.py`, `src/04_eda_joined.py`. Wykresy trafiają do `reports/stage1/figures/`, liczby do `reports/stage1/results/`.

Przygotowane pliki (razem ok. 15 MB) są też w repozytorium, więc analizy można uruchomić bez pobierania danych.

4. Analiza eksploracyjna – zbiór 1 (recenzje)

Metody: statystyki opisowe, 95% przedziały ufności Wilsona dla odsetków, test χ^2 niezależności, test U Manna-Whitneya (z miarą efektu rank-biserial r), porównanie słownictwa metodą log-odds z priorem Dirichleta (Monroe i in., 2008). Wszystkie wartości p podane w raporcie jako „$p < 0.001$" były w rzeczywistości mniejsze niż 10^{-20}.

4.1 Jakość danych i czyszczenie

- Brakujących wartości w kluczowych kolumnach (tekst, ocena, gra) nie ma. Rok w dacie ma brak w 10 119 recenzjach: Steam nie pokazuje roku dla wpisów z bieżącego roku, a w danych nie ma żadnej recenzji z rokiem 2016, więc przyjmujemy, że są to recenzje z 2016 roku (rok zebrania danych).
- 38 recenzji jest pustych, a 874 to powtórzone pary (użytkownik, gra) – wszystkie z identycznym tekstem, czyli kopie powstałe przy zbieraniu danych. Po ich usunięciu zostaje **58 393 recenzji** od 25 444 użytkowników o 3 682 grach.
- Teksty bywają bardzo krótkie: 16.6% recenzji ma najwyżej 3 słowa, a najczęstsze powtarzające się teksty to „good game" (101 razy), „good" (100) i „10/10" (77). Część przekleństw jest zamaskowana przez Steam znakami „♥♥♥♥".
- Język (prosta heurystyka): 69.9% recenzji jest po angielsku, 23.0% jest zbyt krótkich, by to ocenić, 5.9% to inne języki zapisane alfabetem łacińskim, 1.3% to cyrylica lub znaki chińskie, japońskie i koreańskie.

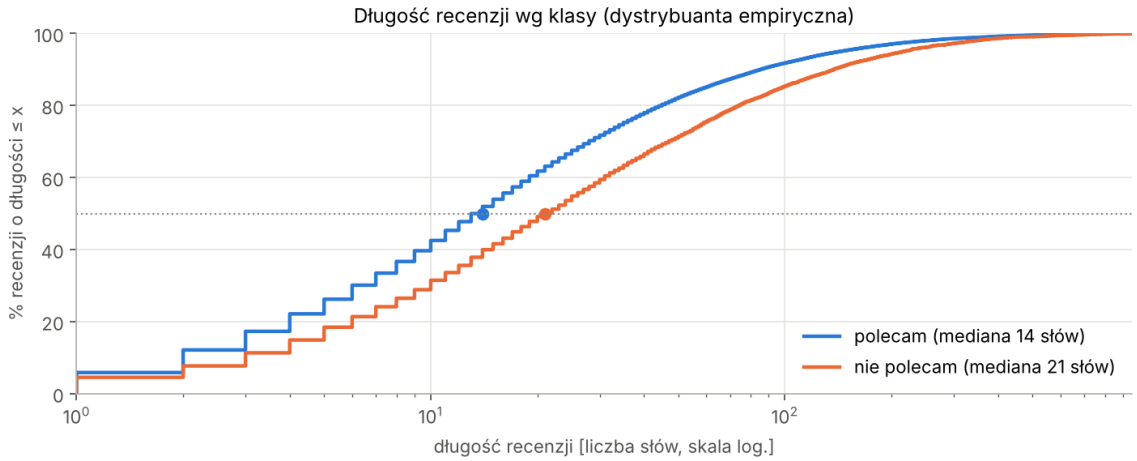
4.2 Zmienna celu i zmiany w czasie



Rysunek 1. Liczba recenzji „polecam" i „nie polecam", liczba recenzji w latach i odsetek „polecam" w latach (2016 – recenzje bez roku w dacie).*

- **Klasy są niezrównoważone:** 88.5% recenzji poleca grę (95% CI: 88.2–88.7%), tylko 11.5% (6 736) nie poleca. W modelach trzeba więc patrzeć na F1 i czułość dla klasy „nie polecam", a nie tylko na trafność.
- **Odsetek „polecam" spada w czasie** z 98.5% w 2010 r. do 81.9% w 2016 r. ($\chi^2 = 1219.7$, df = 6, $p < 0.001$). Najwięcej recenzji pochodzi z lat 2014–2015.

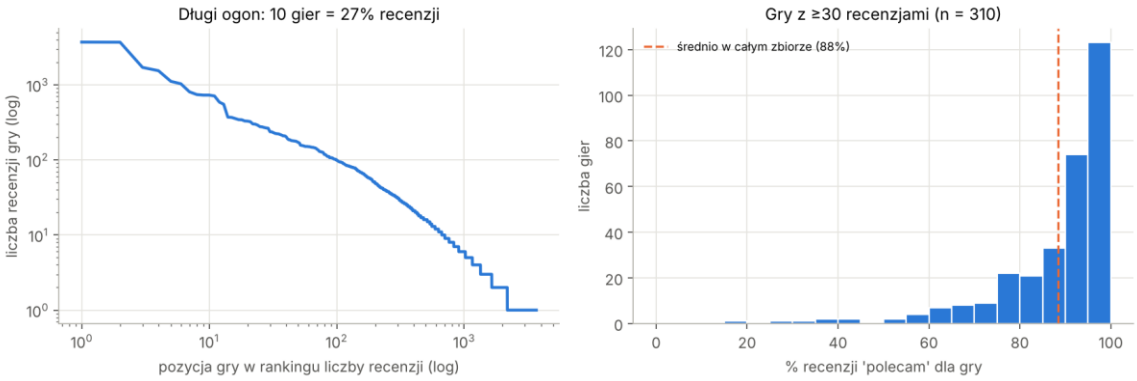
4.3 Długość recenzji



Rysunek 2. Dystrybuanta empiryczna długości recenzji: jaki odsetek recenzji ma co najwyżej x słów.

Mediana długości to 14 słów, średnia 38.7, maksimum 2 667 słów. **Recenzje negatywne są dłuższe:** mediana 21 słów wobec 14 w pozytywnych (test U Manna-Whitneya: $p < 0.001$, $r = 0.17$ – efekt mały). Gracz, który nie poleca gry, częściej uzasadnia swoją ocenę. Recenzje negatywne dostają też więcej głosów „pomocna": mediana 3 wobec 0 ($p < 0.001$, $r = 0.36$).

4.4 Gry w zbiorze recenzji

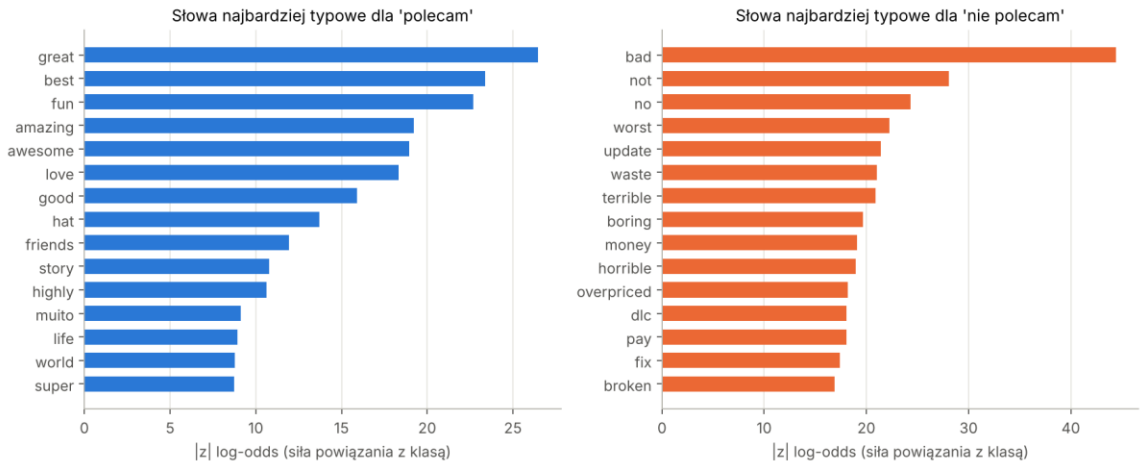


Rysunek 3. Po lewej: liczba recenzji gry względem jej pozycji w rankingu (skala log-log). Po prawej: odsetek „polecam" dla gier z co najmniej 30 recenzjami.

Rozkład jest bardzo skośny: mediana to 2 recenzje na grę, 1 504 gry mają tylko jedną recenzję, a 10 najpopularniejszych gier zbiera 27% wszystkich recenzji (najwięcej: Counter-Strike: Global Offensive,

obecnie Counter-Strike 2, oraz Team Fortress 2 – po ok. 3 700). Wśród 310 gier z co najmniej 30 recenzjami mediana odsetka „polecam” wynosi 93.1%, ale są też gry z odsetkiem poniżej 30%.

4.5 Słownictwo



Rysunek 4. Słowa najsilniej związane z każdą klasą (z-score log-odds; pominięte słowa funkcyjne poza przeczeniami oraz słowa „game” i „play”).

Korpus ma 2.1 mln słów i 68 152 różnych słów, z których 39 566 występuje tylko raz. Słowa typowe dla recenzji pozytywnych to oceny ogólne (great, best, fun, amazing) oraz „friends” i „story”. W recenzjach negatywnych oprócz ocen (bad, worst, terrible) i przeczeń (not, no) pojawiają się **konkretne powody**: aktualizacje i błędy (update, fix, broken) oraz pieniądze (money, overpriced, dlc, pay). To wskazuje tematy, które w kolejnych etapach powinien znaleźć model tematyczny.

5. Analiza eksploracyjna – zbiór 2 (gry)

Metody: statystyki opisowe, analiza braków i zer, korelacja rang Spearmana, testy U Manna-Whitneya, Kruskala-Wallisa i χ^2. Odsetek pozytywnych ocen liczymy tylko dla gier z co najmniej 50 ocenami, bo przy kilku ocenach jest bardzo niestabilny:

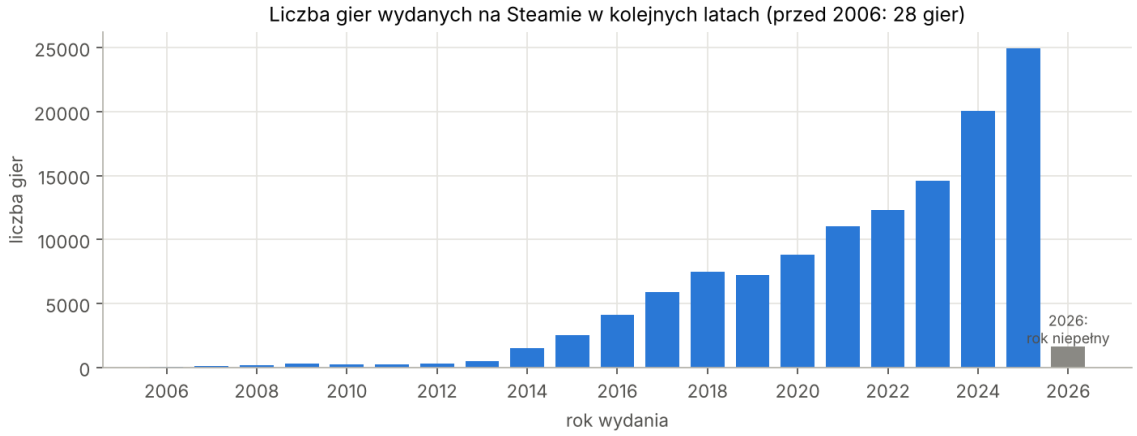
```
\text{odsetek pozytywnych} = \frac{\text{positive}}{\text{positive} + \text{negative}}
```

„Sukces” to co najmniej 80% ocen pozytywnych (na Steamie: ocena „bardzo pozytywna”).

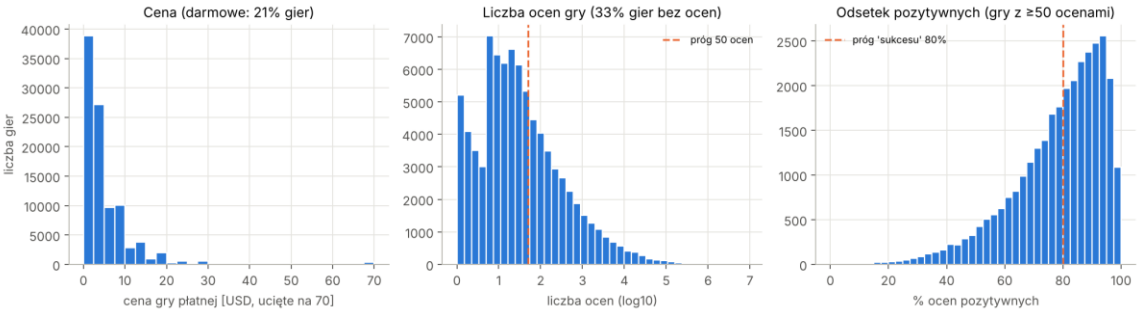
5.1 Jakość danych

- Duplikatów identyfikatora gry ani brakujących wartości liczbowych nie ma, ale **zero często oznacza brak informacji**: ocena Metacritic jest równa 0 dla 96.6% gier, ocena użytkowników Metacritic dla 99.97%, wymagany wiek dla 99.0%, a średni czas gry dla 79.0%. Tych kolumn nie można traktować jak zwykłych liczb.
- 33.2% gier nie ma żadnej oceny, a 23 033 gry mają 0 właścicieli i 0 ocen: 35% z nich ma w nazwie „Playtest” (wersje testowe), a 45% wydano w 2025 r. Liczba właścicieli jest podana tylko w przedziałach (np. „0 – 20000”).
- 8 419 gier nie ma gatunku. Kolumna tagów po wczytaniu z pliku Parquet jest pusta – w etapie 1 korzystamy z gatunków i kategorii, a odczyt tagów sprawdzimy w kolejnym etapie.

5.2 Rozkłady



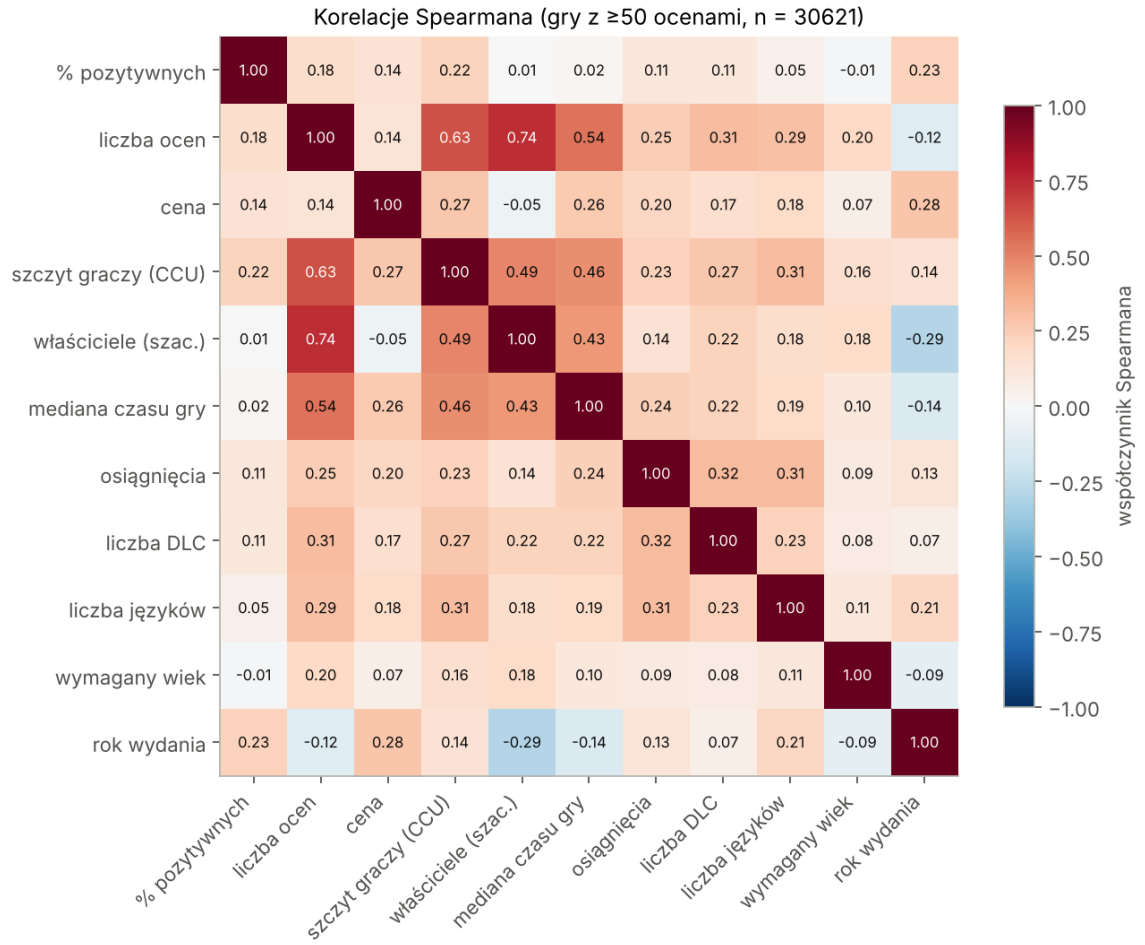
Rysunek 5. Liczba gier wydanych na Steamie w kolejnych latach (2026 – dane zebrane w trakcie roku).



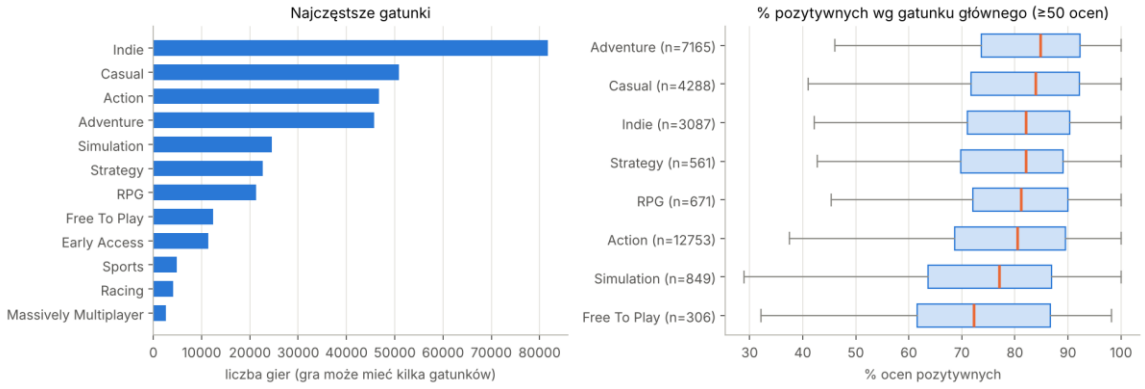
Rysunek 6. Rozkład ceny gier płatnych, liczby ocen (skala log.) i odsetka ocen pozytywnych (gry z co najmniej 50 ocenami).

- Liczba wydawanych gier szybko rośnie: z 467 w 2013 r. do 24 973 w 2025 r.
- 21.3% gier jest darmowych. Gry płatne są zwykle tanie: mediana 3.59 USD, 90% kosztuje najwyżej 11.99 USD.
- Liczba ocen jest skrajnie skośna: mediana 7, 90. percentyl 366, maksimum 8.8 mln. Próg 50 ocen spełnia 30 621 gier (24.7%) i to one są podstawą dalszych analiz ocen.
- Mediana odsetka pozytywnych ocen to 82.0%, a próg „sukcesu” spełnia 55.1% gier. Rozkład jest przesunięty w stronę wysokich ocen.
- Gatunki: najczęściej Indie (81 746 gier), Casual, Action i Adventure; gra może mieć kilka gatunków. 99.96% gier działa na Windows, 17.3% na macOS, 12.8% na Linux.

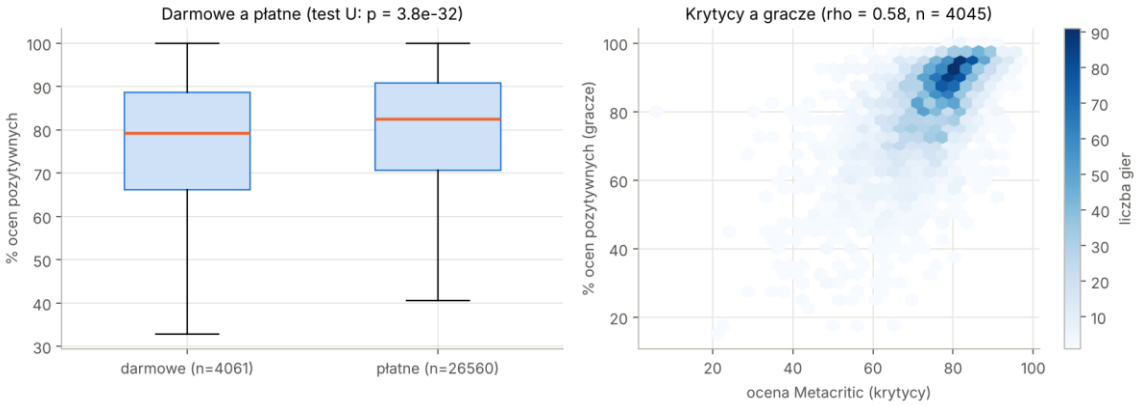
5.3 Zależności i testy statystyczne



Rysunek 7. Korelacje Spearmana między cechami gier z co najmniej 50 ocenami.



Rysunek 8. Najczęstsze gatunki oraz odsetek ocen pozytywnych według gatunku głównego (pierwszego na liście).

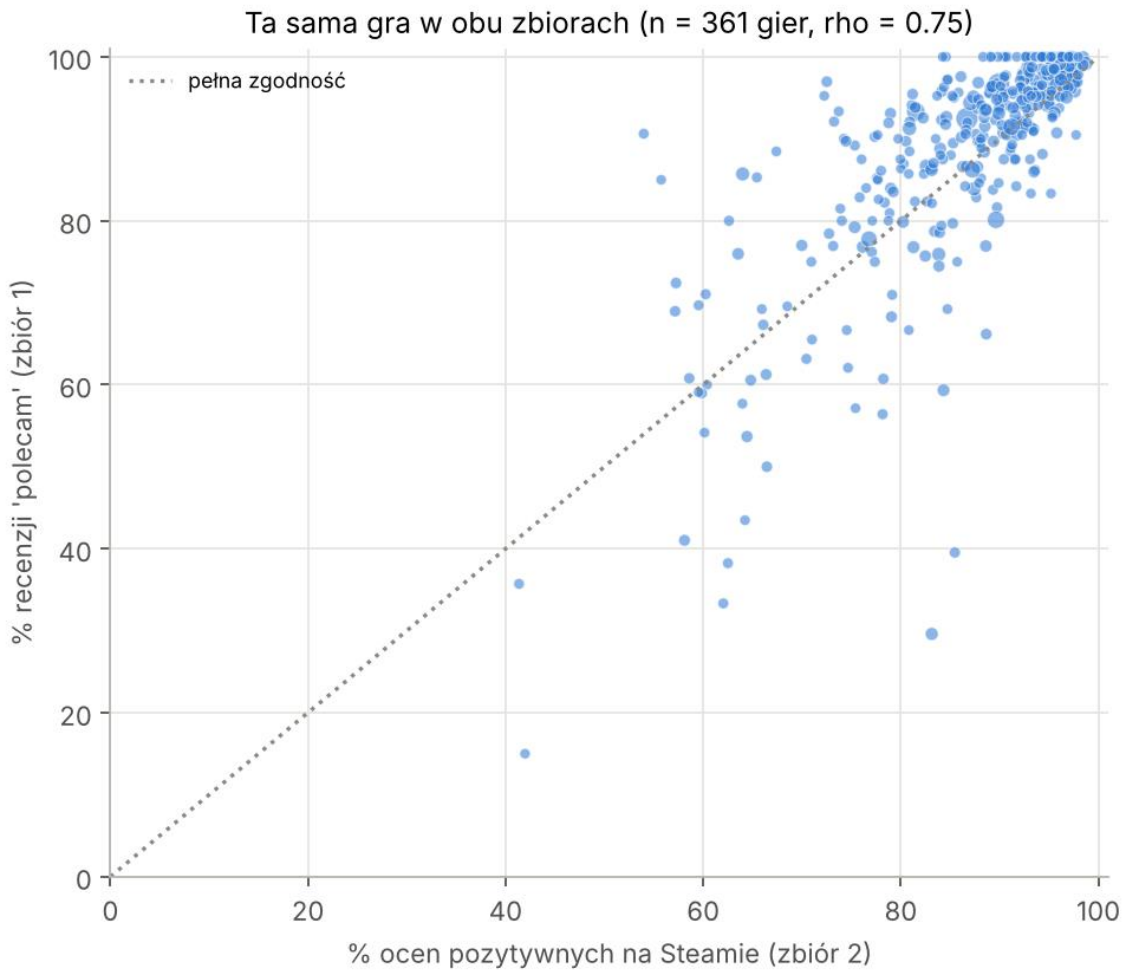


Rysunek 9. Odsetek ocen pozytywnych gier darmowych i płatnych oraz ocena krytyków (Metacritic) wobec ocen graczy.

- **Pojedyncze cechy słabo wiążą się z oceną graczy.** Najsilniejsze korelacje Spearmana z odsetkiem pozytywnych to rok wydania ($\rho = 0.23$), szczytowa liczba graczy (0.22), liczba ocen (0.18) i cena (0.14). Liczba właścicieli, czas gry i wymagany wiek nie mają prawie żadnego związku ($|\rho| \leq 0.02$). Cechy są natomiast silnie skorelowane między sobą: liczba ocen z liczbą właścicieli (0.74) i szczytem graczy (0.63). To mierniki popularności gry, a nie jej jakości.
- **Gry darmowe są oceniane gorzej:** mediana 79.2% wobec 82.4% dla płatnych (test U: $p < 0.001$, $r = 0.11$). „Sukces" osiąga 48.1% gier darmowych i 56.2% płatnych ($\chi^2 = 93.6$, $p < 0.001$).
- **Gatunek ma znaczenie** (Kruskal-Wallis dla 8 najczęstszych gatunków głównych: $H = 549.0$, $p < 0.001$): najwyżej oceniane są gry przygodowe (mediana 84.9%) i casualowe (83.9%), najniżej symulatory (77.1%) i gry Free To Play (72.3%).
- **Krytycy i gracze oceniają podobnie, ale nie tak samo:** korelacja oceny Metacritic z odsetkiem pozytywnych ocen graczy wynosi $\rho = 0.58$ (4 045 gier z oceną Metacritic, $p < 0.001$).

6. Połączenie zbiorów

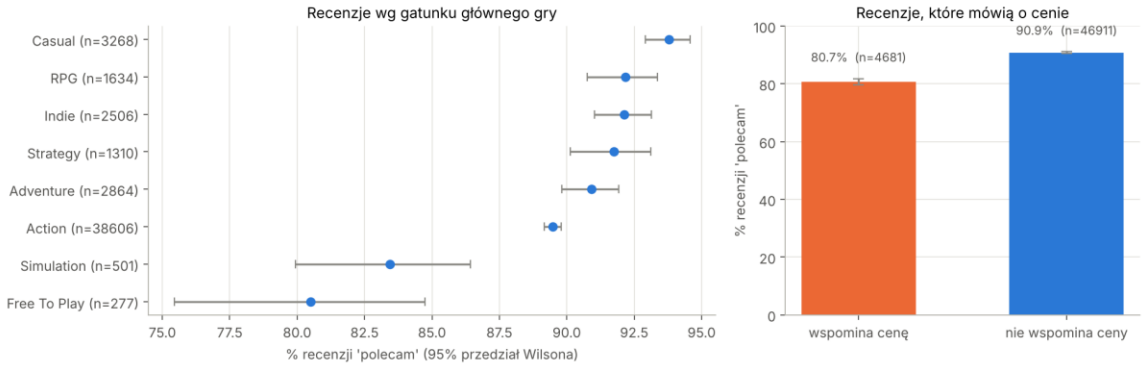
Recenzje łączymy z grami po identyfikatorze gry. W zbiorze gier jest 2 750 z 3 682 gier z recenzji (74.7%); dotyczą one 88.4% recenzji. Pozostałych 932 gier (6 801 recenzji) nie ma w zbiorze 2 – mogą to być tytuły wycofane ze sklepu albo pozycje innego typu; sprawdzimy to w kolejnym etapie.



Rysunek 10. Gry z co najmniej 20 recenzjami w zbiorze 1 i co najmniej 50 ocenami w zbiorze 2: odsetek ocen pozytywnych na Steamie (oś X) wobec odsetka recenzji „polecam" (oś Y). Wielkość punktu = liczba recenzji.

- **Oba zbiory są zgodne:** dla 361 gier korelacja Spearmana między odsetkiem „polecam" w recenzjach a odsetkiem pozytywnych ocen na Steamie wynosi $\rho = 0.75$ ($p < 0.001$), średnia różnica to +2.2 punktu procentowego, a mediana różnicy bezwzględnej 4.5 p.p.
- **Największe rozbieżności mają sens:** No Man's Sky poleca tylko 29.6% ze 179 recenzji z 2016 r. (roku nieudanej premiery), a obecnie na Steamie gra ma 83.1% ocen pozytywnych, bo przez kolejne lata była rozwijana i poprawiana. Podobnie Call of Duty: Black Ops III (59.3% wobec 84.3%). Recenzje opisują ocenę z chwili pisania, a zbiór 2 – stan obecny.
- **Na poziomie recenzji cena gry nie ma znaczenia:** recenzje gier darmowych i płatnych polecają je równie często (90.2% wobec 89.8%, $\chi^2 = 1.6$, $p = 0.21$). To różni się od wyniku dla wszystkich gier na Steamie, gdzie darmowe wypadają gorzej. Dwa możliwe powody: w zbiorze recenzji dominują bardzo popularne darmowe gry (Team Fortress 2, Dota 2), a cena pochodzi ze zbioru 2, czyli ze stanu obecnego – np. Counter-Strike: Global Offensive (obecnie Counter-Strike 2; 3 704 recenzje z lat 2012–2016) jest dziś darmowy, a w czasie pisania recenzji był płatny.

- **Liczy się natomiast to, czy recenzja mówi o pieniądzach:** 9.1% recenzji wspomina cenę (price, money, worth, refund, overpriced itp.), a takie recenzje polecają grę w 80.7% przypadków wobec 90.9% pozostałych ($\chi^2 = 482.3$, $p < 0.001$). O cenie częściej piszą gracze gier płatnych (10.6%) niż darmowych (6.4%).
- Odsetek „polecam" różni się też między gatunkami głównymi ($\chi^2 = 143.9$, $df = 7$, $p < 0.001$): od 93.8% dla gier Casual do 80.5% dla Free To Play (rysunek 11).



Rysunek 11. Odsetek recenzji „polecam" według gatunku głównego gry oraz według tego, czy recenzja wspomina o cenie (95% przedziały Wilsona).

7. Pytania badawcze

Pytanie główne: co decyduje o tym, że gra na Steamie jest dobrze oceniana przez graczy, i czy można to przewidzieć z tekstu recenzji oraz z cech gry?

- **P1. Tekst recenzji (uczenie nadzorowane, NLP).** Czy na podstawie samego tekstu da się przewidzieć, czy gracz poleca grę? Jak model klasyczny (TF-IDF + regresja logistyczna) wypada w porównaniu z modelem opartym na transformerach (np. DistilBERT), zwłaszcza dla rzadszej klasy „nie polecam" (11.5%) i dla bardzo krótkich recenzji (16.6% ma najwyżej 3 słowa)?
- **P2. Tematy recenzji (uczenie nienadzorowane, NLP).** O czym piszą gracze i które tematy przeważają w recenzjach negatywnych? Analiza słownictwa sugeruje tematy: cena i DLC, aktualizacje i błędy, gra ze znajomymi, fabuła.
- **P3. Cechy gry a ocena (uczenie nadzorowane).** Na ile cechy gry – cena, gatunek, platformy, liczba języków, osiągnięcia, DLC, rok wydania – pozwalają przewidzieć odsetek pozytywnych ocen lub „sukces" (co najmniej 80%)? Które cechy są najważniejsze? Słabe korelacje pojedynczych cech ($|\rho| \leq 0.23$) sugerują, że liczy się raczej ich kombinacja niż jedna cecha.
- **P4. Segmenty gier (uczenie nienadzorowane).** Czy gry tworzą naturalne grupy, np. darmowe gry sieciowe, tanie gry niezależne, duże produkcje, i czy grupy różnią się ocenami graczy?
- **P5. Tekst a liczby (oba zbiory).** Czy ocena wyliczona z tekstu recenzji zgadza się z odsetkiem pozytywnych ocen na Steamie, i kiedy się rozjeżdża – ze względu na czas (No Man's Sky), cenę lub gatunek? Czy spadek odsetka „polecam" z 98.5% w 2010 r. do 81.9% w 2016 r. wynika ze zmiany rodzaju recenzowanych gier, czy z ostrzejszych ocen?

Planowane metody w kolejnych etapach: uczenie nadzorowane – regresja logistyczna i las losowy lub gradient boosting; uczenie nienadzorowane – k-średnich z PCA dla gier oraz modelowanie tematów

(LDA) dla recenzji; model transformerowy (DistilBERT) do klasyfikacji recenzji; prosty interfejs w Gradio do sprawdzania wyników (ocena dowolnego tekstu recenzji i prognoza oceny dla podanych cech gry).

8. Ograniczenia

- Zbiór 1 obejmuje tylko recenzje użytkowników z Australii z lat 2010–2016, więc nie jest reprezentatywny dla wszystkich graczy ani dla dzisiejszego Steama.
- Zbiory pochodzą z różnych lat: recenzje z lat 2010–2016, oceny gier według stanu z 2026 r. Część różnic między zbiorami wynika z czasu, a nie z błędów.
- Rozpoznawanie języka jest uproszczoną heurystyką, a liczba właścicieli jest podana tylko w przedziałach.
- Odsetek pozytywnych ocen liczymy tylko dla gier z co najmniej 50 ocenami. To 24.7% wszystkich gier, głównie popularniejsze tytuły.

9. Repozytorium

Kod, przygotowane dane, wykresy, wyniki liczbowe i raporty: https://github.com/ProstoKery/steam-ml-project. Plik `README.md` opisuje, jak odtworzyć wyniki. Repozytorium (kod, opisy i wykresy) jest przygotowane w języku angielskim i zawiera też angielską wersję tego raportu.